

CNN을 이용한 뇌전증 발작예측에 관한 연구

류상욱* · 이남화* · 이연수* · 조인휘* · 민경욱** · 김택수***†

*한양대학교 공과대학 컴퓨터소프트웨어학부,

한양대학교 공과대학 융합전자공학부, *‡(주)이디에이엘리텍

A Study on the Epileptic Seizure Prediction using CNN

Sanguk Ryu*, Namhwa Lee*, Yeonsu Lee*, Inwhee Joe*,

Kyeongyuk Min** and Taeksoo Kim***†

*Department of Computer Software, Hanyang University,

**Department of Electronic Engineering, Hanyang University,

***‡EDA Elitech Co. Ltd.

ABSTRACT

In this paper, the new architecture of seizure prediction using CNN and LSTM and DWT was presented. In the proposed architecture, EEG data was labeled into a preictal and interictal section, and DWT was adopted to the preprocessing process to apply the characteristics of the time and frequency domain of the processed EEG signal. Also, CNN was applied to extract the spatial characteristics of each electrode used for EEG measurement, and LSTM neural network was applied to verify the logical order of the preictal section. The learning of the proposed architecture utilizes the CHB-MIT Scalp EEG dataset, and the sliding window technique is applied to balance the dataset between the number of interictal sections and the number of preictal sections. As a result of the simulation of the proposed architecture, a sensitivity of 81.22% and an FPR of 0.174 were obtained.

Key Words : EEG, Epilepsy EEG, Interictal, Preictal, Seizure, CNN, LSTM

1. 서 론

뇌전증 발작(epileptic seizure) 혹은 뇌전증(epilepsy)은 세계 인구의 약 1%에 영향을 미치는 신경계 장애이다[1]. 비정상 뇌파는 뇌전증 발작을 유발하며, 환자의 증상은 ictal EEG의 발생위치와 강도에 따라 다르다. 의학적으로 완치할 수 없는 발작은 환자의 활동에 제약이 따르게 되며, 이 경우 환자는 독립적으로 일하고 활동을 할 수 없다. 이러한 현상은 개인의 사회적 고립과 경제적 어려움으로 이어진다.

발작(Seizure)의 위치와 영역에 따라 뇌전증은 국소 뇌전

증과 전신 뇌전증의 두 가지 범주로 구분된다. 국소 뇌전증은 뇌의 특정 영역에서의 장애이며, 일반적인 뇌전증은 뇌 전체 영역의 이상 징후를 특징으로 하는 전신 뇌전증이다. 뇌전증을 진단하고 치료하기 위해서는 뇌전증 발작의 발생영역을 찾기 위해 뇌파 신호 분석이 필요하다.

뇌파(EEG)에는 두개내 뇌파(Intracranial EEG)와 두피뇌파(Scalp EEG) 유형이 있다. Intracranial EEG는 두개골과 두피로 인한 노이즈가 거의 없지만 두개골에 전극을 부착하기 위해서 외과적 수술이 필요하기 때문에 측정하기 어렵다.

한편, scalp EEG는 다양한 뇌의 생리분석과 뇌전증 발작 분석에 사용되며, 수술 없이 데이터를 수집할 수 있지만, 노이즈가 많아 seizure(발작)신호의 분석을 방해하는 요소가 존재한다. 뇌전증의 진단 및 치료를 위해서는 발작 초

†E-mail: tskim@ellitech.net

기에 뇌파를 관찰하고 분석하는 것이 중요하다. 뇌전증 발작의 대부분은 EEG 신호를 육안으로 검사하여 의료 전문가가 진단하여 왔다.

발작 시 발작 증상 과정에 대한 환자 본인의 인지가 불가능하며, 발작 후 주변 상황을 통한 본인의 발작여부를 인지할 수 있기 때문에 환자가 느끼는 사회적 상실감이 매우 크다. 따라서 뇌전증 발작을 예측 할 수 있다면, 환자 스스로가 자신의 안전 및 자존감을 지킬 수 있다. Seizure 발생 전 환자 스스로가 통제 가능한 시간을 최소 30분이라 가정하였고, 본 논문은 30분 이내에서 발작예측성능이 좋은 예측 시스템을 구현하는데 목적을 두었다.

의료분야에서는 인공신경망을 이용하여 병을 진단하고 진행 상태를 예측하는 연구가 다양하게 진행되고 있으며, 특히 뇌전증 분야에서는 인공신경망을 이용하여 발작검출 및 예측하는 연구가 진행되고 있다. 최근에는 고성능 컴퓨팅 파워의 출현으로 심층신경망[2] 기반의 발작 예측 방법이 제안되고 있으며 이에 따른 발작예측을 위한 인공신경망 네트워크 아키텍처가 연구되고 있다.

2. 심층신경망과 뇌전증 발작예측

2.1 Electroencephalogram(EEG)

본 연구에서는 두피에 전극을 부착하여 측정하는 ‘두피뇌파(Scalp EEG)’를 이용하였다. 뇌파측정은 Fig. 1과 같이 전극을 두피에 부착하여 측정한다. 전극의 위치는 10-20 전극체계에 따라 결정되며 주로 단기간 측정에 흔히 사용되는 방식이다. 전극배치는 전두엽-후두엽 간 또는 좌측-우측 측두엽 간 전극간 거리로 구분된다. 이 거리가 10% 또는 20%씩 일정하게 나누어 배치하기 때문에 10-20 전극배치법 이라 한다. 최근에는 거리를 좁혀 많은 전극을 부착하는 방식인 10-5 전극 배치법이 국제표준으로 사용되고 있다.




Fig. 1. International 10-20 system.

데이터는 참조전극(Reference electrode) 선택 방식에 따라 ‘Average Reference’ 방식과 ‘Bipolar Reference’ 방식으로 구분되며, 본 연구에서는 CHB-MIT 데이터셋의 ‘Bipolar Reference’ 방식을 이용하였다.

2.2 Epilepsy EEG

2.2.1 Epilepsy EEG 구성

EEG는 Interictal, Preictal, ictal(또는 Seizure) 그리고 Postictal로 구성된다.




Fig. 2. Partition of Epilepsy signal in single Ch. EEG.

정상뇌파인 Interictal 경우, Time-domain의 특징은 진폭이 $-25 \sim 25\mu V$ 사이의 안정된 신호로 측정된다. Frequency-domain은 저주파 대역($0 \sim 14\text{Hz}$, Delta-Alpha) 대역으로 구성되며 50Hz 이상 신호의 경우 노이즈로 간주한다[3].

Preictal의 특징은 진폭이 $-100 \sim 100\mu V$ 사이로 측정되며, Ictal구간은 Seizure 신호가 발생한다. Ictal 구간의 특징을 두 가지로 나눌 수 있다. 그 특징은 time-domain에서 분석할 경우, Amplitude의 최대진폭의 차이가 급격하게 커지고, 그 후 일정시간동안 Ictal이 서서히 감소하는 양상을 보이며, seizure가 발생할 때 일정한 리듬이 반복되는 양상을 보인다. Frequency domain에서는 Interictal 구간보다 ictal 구간이 저주파($0 \sim 7\text{Hz}$, Delta-Theta)구간에 파워가 집중되어 있다[4]. Postictal은 ictal이 소강상태를 보이며, preictal과 비슷하지만 신호가 reset된 형상을 보인다.

2.2.2 뇌전증 발작 예측(Epileptic Seizure Prediction)

뇌전증 발작 예측연구는 뇌전도 분석을 통해 발작의 검출 후 학습을 시켜 예측을 한다. 발작이 발생하면 뇌파의 전 채널에서 발생하며 이 파형은 개인마다 다른 양상을 보인다. Ictal EEG 및 스펙트럼 특성을 갖는 EEG 채널의 위치는 환자의 증상에 따라 다르게 검출된다. 또한 환자의 눈 깜박임, 팔과 다리근육 활동과 같은 발작이 아닌 상태와 발작 할 때 신체 활동은 뇌파 신호에 반영 된다. 그렇기 때문에 EEG 신호의 특성은 seizure가 발생할 때의 신호를 신체 활동관련 뇌파로 인해 오탐지 하기 때문에 EEG prediction이 어려운 이유 중 하나다.

2.3 Convolutional Neural Network (CNN)

CNN은 픽셀 이미지에서 최소한의 전처리(Preprocessing) 방법을 적용하여 패턴 분류방식으로 다양한 이미지 인식에 적용될 수 있다[5]. 이 model은 기존 패턴 인식 방법에서 두 단계의 feature extraction 및 classification을 한 단계로 결합한 통합 모델이다. Fig. 3에 CNN 전체 구조를 나타내었다.




Fig. 3. General Architecture of CNN.

3. CNN과 LSTM을 이용한 뇌전증 발작예측

제안하는 논문은 interictal과 preictal을 구별하여 preictal을 예측하는 것으로, 이를 위해서 각 데이터 세트에 포함된 각 환자의 뇌파 데이터를 사용하였다. 본 논문에서는 Fig. 4와 같이 Supervised learning method를 사용하여 네트워크를 구성하였고, interictal과 preictal을 구별하는 방법을 적용하였다.




Fig. 4. Proposed Seizure Prediction System.

3.1 Dataset (CHB-MIT)

CHB-MIT 데이터셋[6]은 EEG를 이용한 발작 탐지 및 예측 관련 논문에서 주로 사용되는 검증된 데이터이며, Children's Hospital of Boston에서 수집된 연속적인 Scalp EEG를 기록한 데이터로 844시간과 245번의 Ictal을 가진 24명의 소아 환자의 데이터이다. 기록된 신호는 sampling rate 256Hz인 22개의 전극을 사용하였고 bipolar 방법으로 추출하였다. 22개의 전극 채널 중 공통되는 18개의 채널을 사용하였다. 또한 interictal은 ictal에서 최소 3시간정도 떨어진 거리에 있는 구간을 사용하였고, 짧은 시간에 반복적으로 발생하는 ictal은 preictal구간을 충분히 가져갈 수 없다고 판단하여 제외하였다.

3.2 Preprocessing of EEG signal

제안하는 구조에서는 전처리방법으로 Wavelet 변환을

적용하였다. Wavelet 변환은 주파수 대역의 특성을 다양하게 볼 수 없는 Short Time Fourier Transform (STFT)의 단점을 보완한 방법이다. Wavelet 변환은 고주파수나 저주파수의 모든 영역에서 효과적으로 해석이 가능한 방법으로 기본 함수 Sine, Cosine 함수 이외에 Wavelet 모함수(mother function)를 사용한다. 대표적으로 DWT[7]에서 사용하는 모함수의 경우 Haar, Daubechies 등이 있다.

Wavelet 변환에서 연속적인 주파수 대역을 처리하는 Continuous Wavelet Transform (CWT) 연산량이 크기 때문에 시간이 오래 걸린다. 이 문제를 해결하기 위하여 주파수 대역을 선택하여 진행하게 되면 CWT의 연속성이 사라지게 된다. 따라서 본 연구에서는 주파수 대역을 이산적으로 처리하여 연산량이 적고 속도가 빠른 Discrete Wavelet Transform (DWT)를 적용하였다.

DWT를 사용하게 되면 STFT보다 Time-domain에서 많은 데이터 수가 나오게 되어 연산량이 커지기 때문에 최적의 Window size를 정하기 위해 CHB-MIT 공공 데이터를 이용하여 Window size 5, 10초에 대한 실험을 진행하였으며, Window size가 10초일 때, 최적의 성능을 보였다.

Fig. 5와 같이 원본 신호를 각 채널 별로 분리하고, 이 데이터를 Window size(5, 10초)로 분할하여 DWT의 mother wavelet (Daubechies 4)을 적용한 후 나온 coefficient를 이용하여 딥러닝 모델의 입력 데이터로 사용하였다.




Fig. 5. Processing Flow of Proposed System.

3.3 Proposed CNN+LSTM Model

제안하는 CNN과 Long Short-Term Memory (LSTM)의 구조를 Fig. 6에 나타내었다.

본 논문에서는 이미지 처리에서 일반적으로 사용되는 CNN모델에 시간적 정보를 반영하기 위해 LSTM모델을 결합한 하이브리드 형태의 모델을 제안 하였다. 제안하는 구조에서는 차원이 줄어드는 것을 막기 위해 Convolution 연산에서 zero padding 처리를 하였으며, Max pooling layer를 통해 feature의 특징을 강화하고 제안하는 Deep Neural Network (DNN)모델의 파라미터가 과도하게 늘어나는 문제를 해결하였다. 또한 학습데이터에 과적합을 방지하기 위해 Batch Normalization 및 dropout layer를 적용하였으며 LSTM을 이용해 feature에 대한 시퀀스 정보를 반영하여

